Presentación Ejecutiva — Análisis E-Commerce

Dataset: E-Commerce · 2016–2018
Fecha: Marzo 2026
Alcance: Análisis de negocio · Python · Machine Learning · IA Conversacional

---

Resumen

Este informe presenta los resultados del análisis de negocio realizados sobre el dataset de una plataforma de e-commerce brasileña con datos de 2016 a 2018. El objetivo fue extraer accionables en áreas de producto, cliente, recomendación y expansión física.

Arquitectura del proyecto

El proyecto está organizado en modulos, con separación entre datos fuente, lógica de análisis y resultados exportados.

- **data**: contiene los datasets fuente.
- **results**: guarda las salidas finales de cada punto.
- **technical_test/answers**: reúne los módulos que resuelven cada pregunta de negocio por separado.
- **technical_test/utils**: concentra utilidades compartidas, como consultas y exportación de resultados.
- **technical_test/main.py**: actúa como punto de orquestación para ejecutar los análisis de forma ordenada.

Esta arquitectura permite tener una trazabilidad completa, brindando claridad sobre el flujo de datos y los resultados generados, además, ofrece escalabilidad al facilitar la incorporación de nuevos análisis o módulos, garantiza mantenibilidad mediante cambios aislados sin afectar todo el sistema y mejora la eficiencia operativa gracias a una ejecución ordenada y la reutilización de componentes.

Productos y categorías más vendidos

Se evaluó el desempeño de las categorías desde dos perspectivas complementarias: volumen de unidades vendidas e ingresos totales generados. El análisis se realizó a nivel de categoría ya que los nombres individuales no están disponibles en el dataset.

Top 5 por volumen (unidades)	Top 5 por ingresos (BRL)
bed_bath_table — 11,115	health_beauty — R$ 1,258,681
health_beauty — 9,670	watches_gifts — R$ 1,205,006
sports_leisure — 8,641	bed_bath_table — R$ 1,036,989
furniture_decor — 8,334	sports_leisure — R$ 988,049
computers_accessories — 7,827	computers_accessories — R$ 911,954

No existe una categoría dominante en todos los frentes. **bed_bath_table** lidera en rotación, mientras **health_beauty** lidera en facturación. Adicionalmente, **watches_gifts** aparece entre las categorías de mayor ingreso sin estar en el top 5 de volumen, lo que sugiere un mayor valor económico por unidad vendida.

Top categorías por volumen

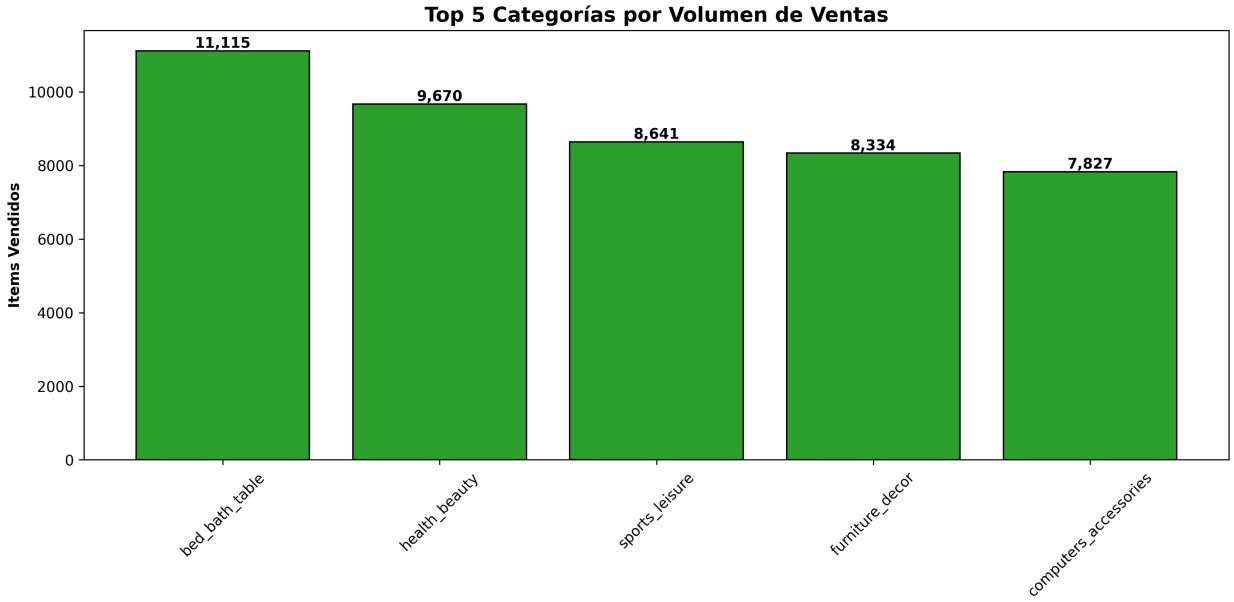

Top categorías por ingresos

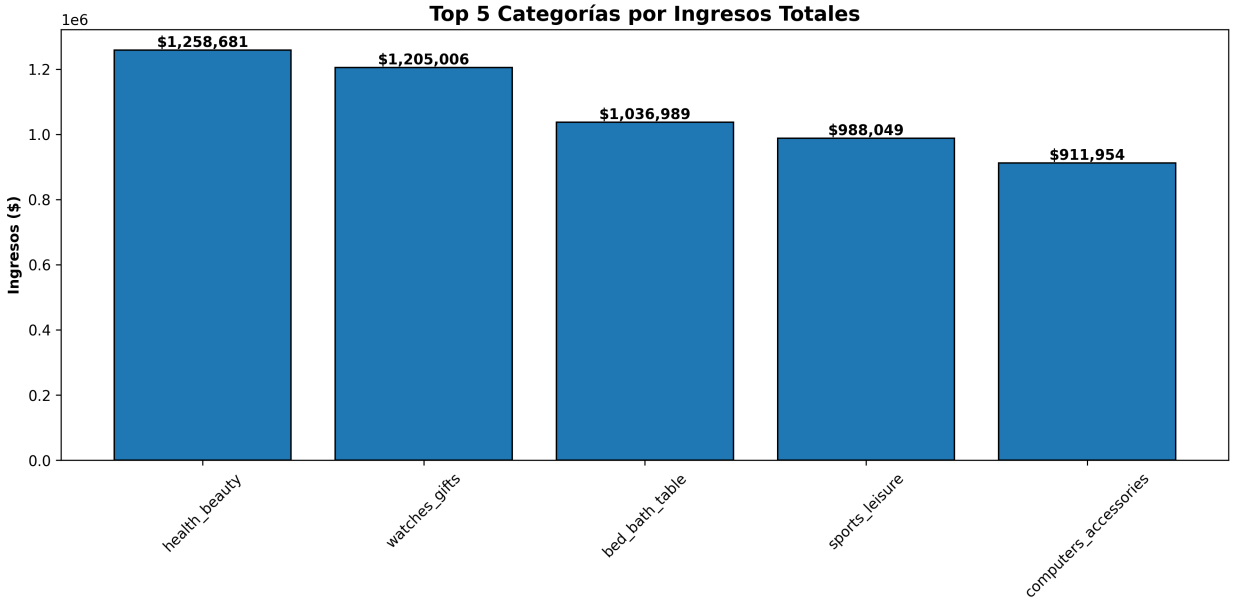

Dolor del cliente y productos relacionados

Se abordó el análisis en dos niveles: categoría y producto individual. La métrica principal fue el promedio de la calificación y la proporción de reseñas negativas.

Categoría	Indicador de problema
diapers_and_hygiene	Calificación promedio: 3.26
office_furniture	34.84% de reseñas negativas (440 de 1,263)

Categoría	Indicador de problema
fashion_male_clothing	Calificación baja con volumen significativo
fixed_telephony	Calificación baja con volumen significativo
garden_tools	Mayor concentración de productos criticados

Cuando se baja al detalle de producto, aparecen casos más claros. Hay artículos con ratings cercanos a **1.1** y **1.3**, acompañados por decenas de reseñas negativas. Dentro de los 20 productos más problemáticos se repiten varias veces categorías como **computers_accessories**, **garden_tools** y **watches_gifts**. Esa repetición sugiere que el problema no está limitado a una sola referencia, sino que puede existir una fricción más amplia dentro de ciertas familias de producto.

El gráfico de categorías con peor rating ofrece una vista general del problema. Sirve para detectar en qué grupos de producto la experiencia del cliente está más comprometida y, por tanto, dónde conviene priorizar revisiones.

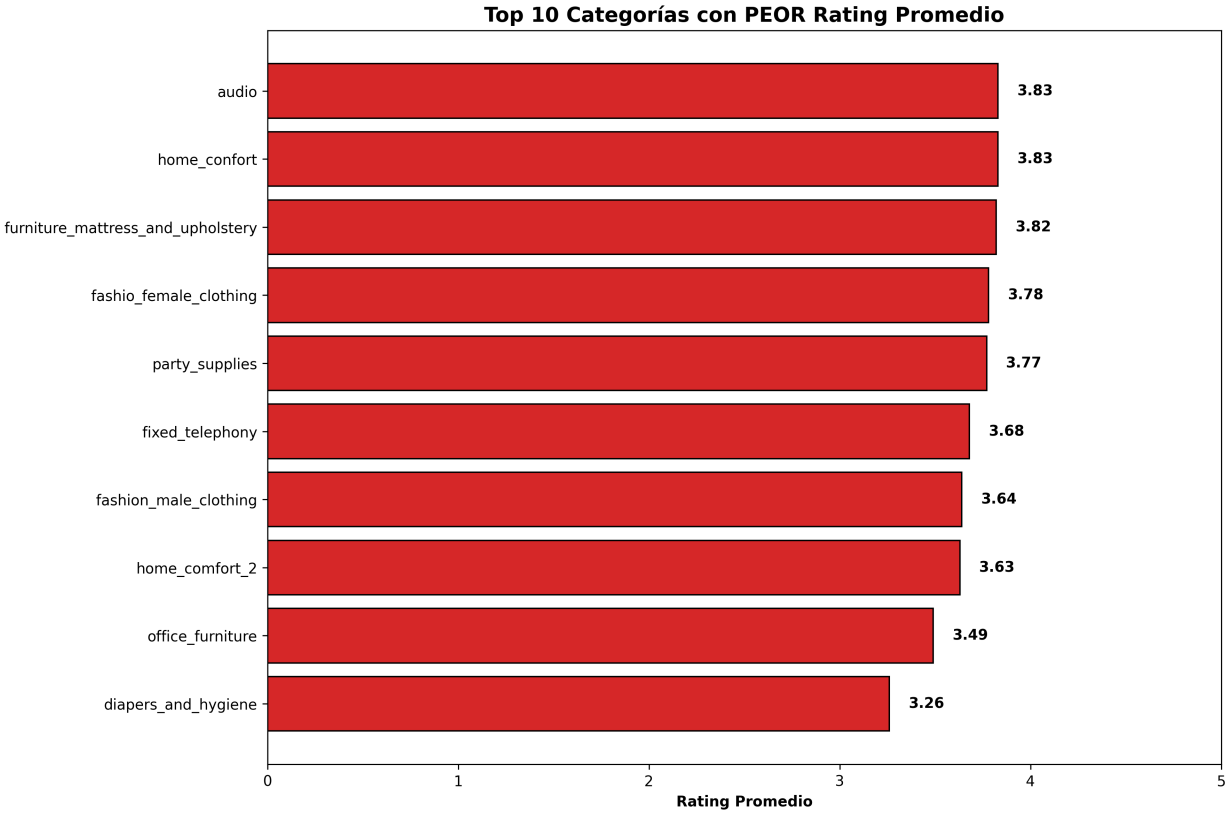

El gráfico de productos más criticados permite pasar de una alerta general a referencias concretas, lo que facilita tomar decisiones de corrección más directas sobre productos específicos.

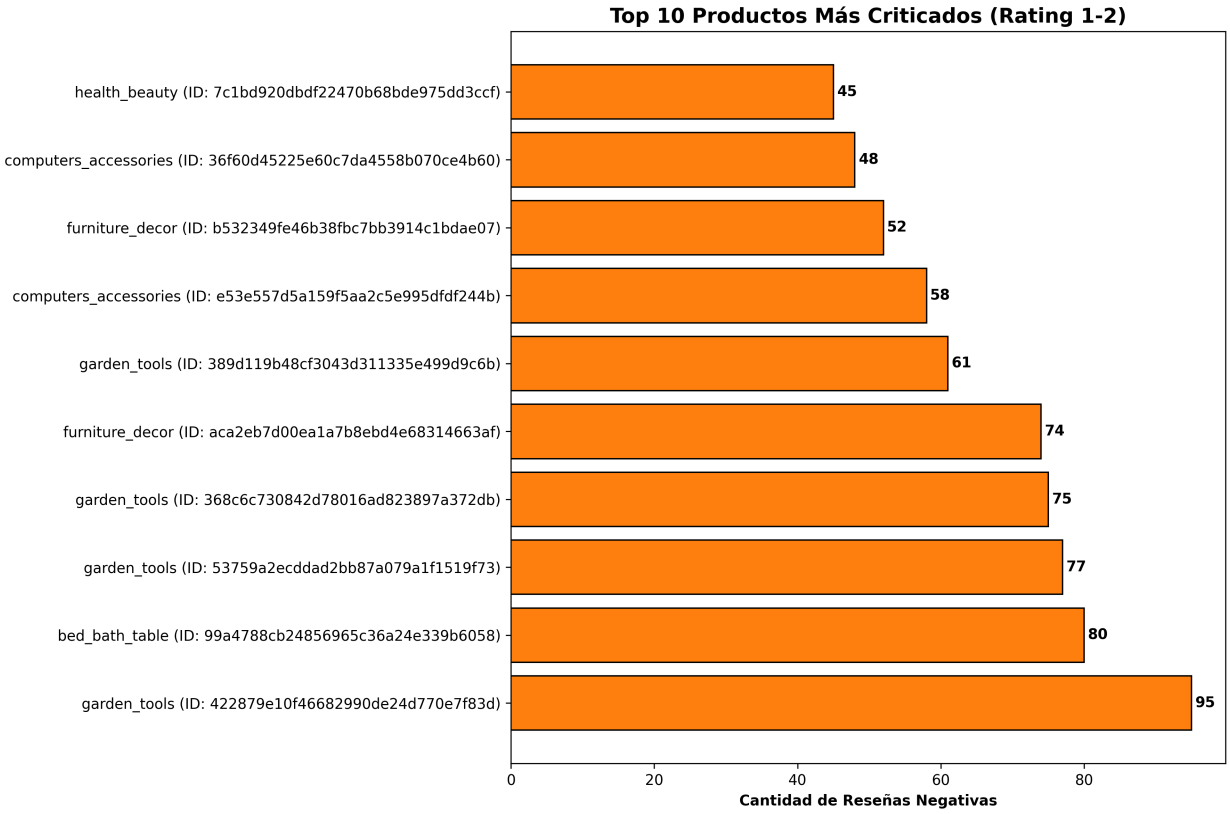

Segmentación de clientes

Se construyó una tabla RFM (Recency, Frequency, Monetary) por cliente único, se escalaron las variables con `StandardScaler` y se aplicó KMeans con k óptimo determinado automáticamente por Silhouette Score (rango k=2 a 7). El k=2 resultó óptimo con un score de 0.739, muy por encima del k=3 (0.456), lo que sugiere una mejor separación entre dos clusters.

La lógica general se apoyó en el enfoque **RFM**, que mira tres dimensiones:

- **Recencia**: hace cuánto tiempo fue la última compra.
- **Frecuencia**: cuántas compras ha realizado el cliente.
- **Monetario**: cuánto dinero ha gastado.

Métricas globales de la base:

Métrica	Valor
Clientes únicos analizados	93,358
Recencia media	237.94 días
Frecuencia media	1.03 compras
Gasto medio	R$ 165.20
Máximo de compras (un cliente)	15 pedidos
Máximo de gasto (un cliente)	R$ 13,664.08

Segmentos identificados:

Métrica	En Riesgo	Clientes Fieles
Clientes	90,548 (97%)	2,810 (3%)
Recencia media	238.49 días	220.41 días
Frecuencia media	1.00 compra	2.11 compras
Gasto medio	R$ 160.10	R$ 329.51
Gasto total	R$ 14,496,546	R$ 925,915
RFM score medio	7.42	10.12

Se observó una dispersión clara en el comportamiento, con clientes que llegaron hasta **15 compras** y otros con gasto acumulado de hasta **13,664.08 BRL**.

Clientes Fieles es un grupo pequeño (3%) pero de alto valor individual, más del doble de frecuencia y gasto respecto a **En Riesgo**. La base está dominada por compradores únicos que necesitan estrategias de reactivación. La distribución de Frequency está fuertemente concentrada en 1.0, lo que confirma que la mayoría de clientes compró una sola vez.

Esta distinción permite pensar acciones diferentes:

- Para **Clientes Fieles**: retención, beneficios diferenciales, venta cruzada y estrategias de valor.
- Para **En Riesgo**: campañas de reactivación, recordación y ofertas más oportunas.

La distribución RFM muestra cómo se reparte la base en las tres variables principales. Es una buena forma de entender si el negocio depende sobre todo de compras únicas o si existe una capa más sólida de recurrencia y gasto.

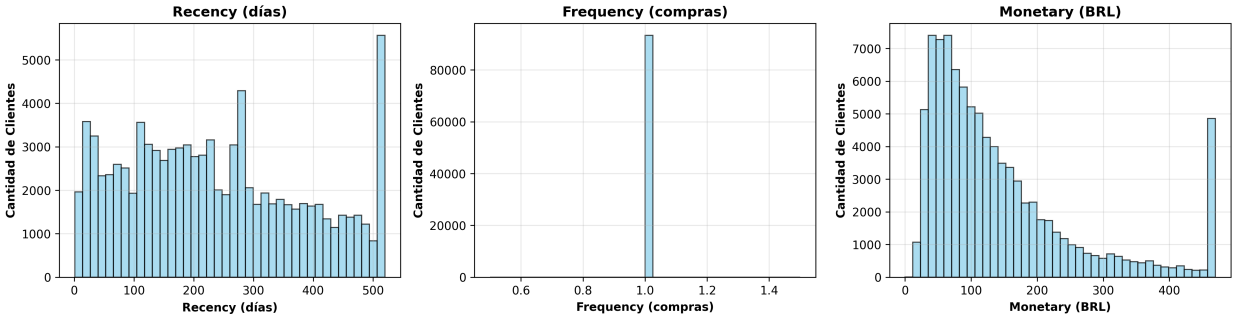

El gráfico de métricas por segmento ayuda a comparar de forma rápida la intensidad de cada grupo.

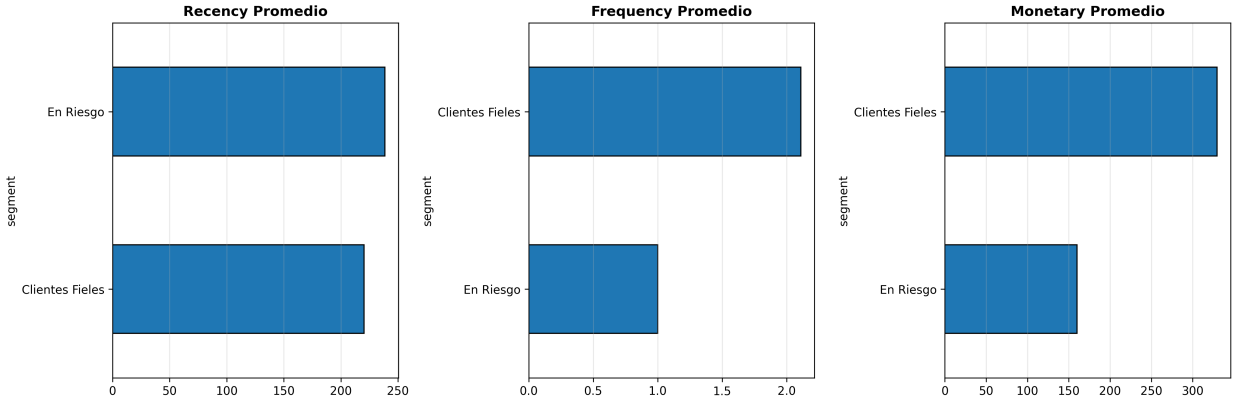

La distribución de segmentos deja claro el peso relativo de cada grupo. Visualmente, ayuda a dimensionar que la mayor parte de la base está concentrada en **En Riesgo**, lo que vuelve prioritaria una estrategia de reactivación.

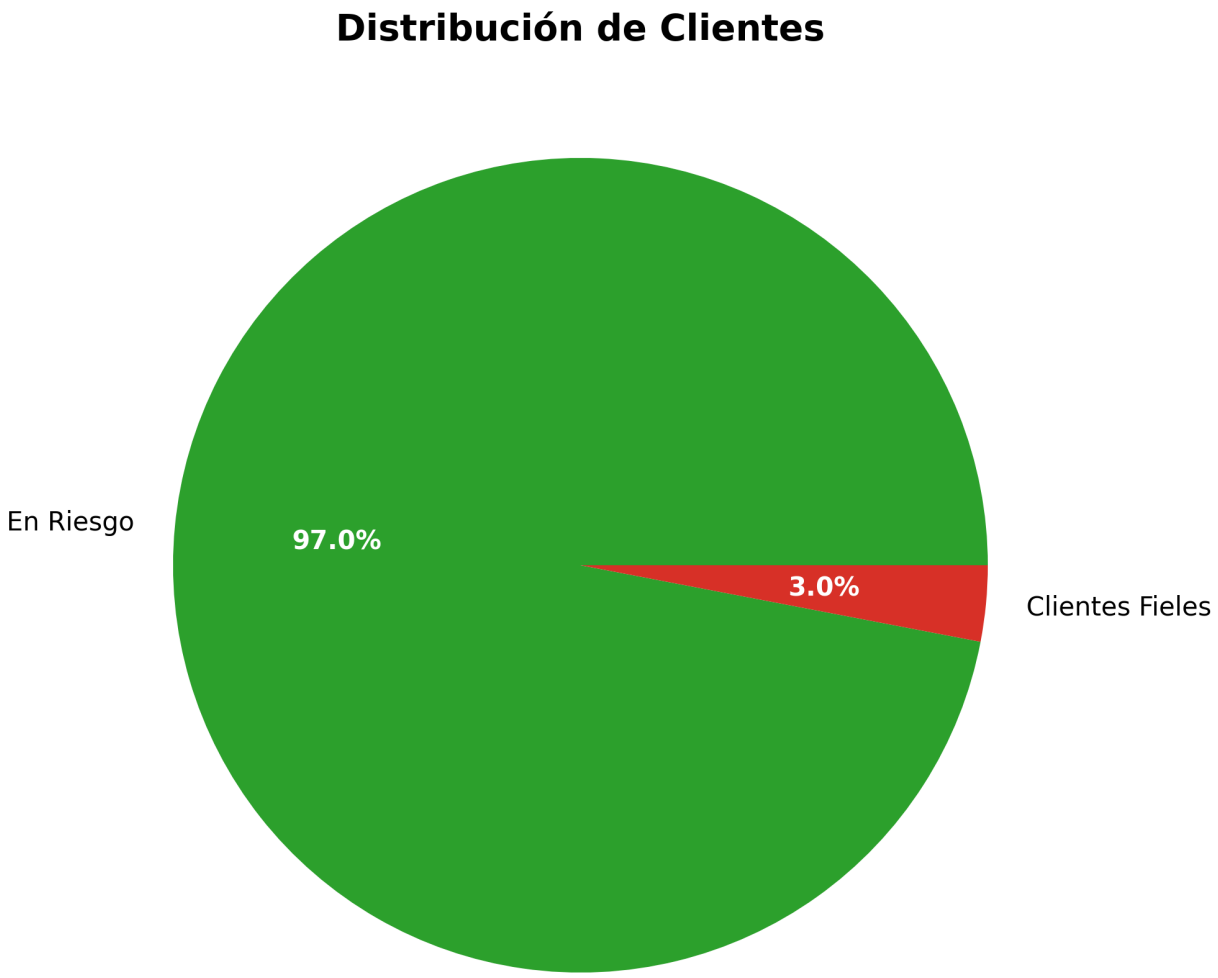

El gráfico de ingresos por segmento aporta una lectura económica. No solo muestra cuántos clientes hay en cada grupo, sino cómo se distribuye el valor total que generan.

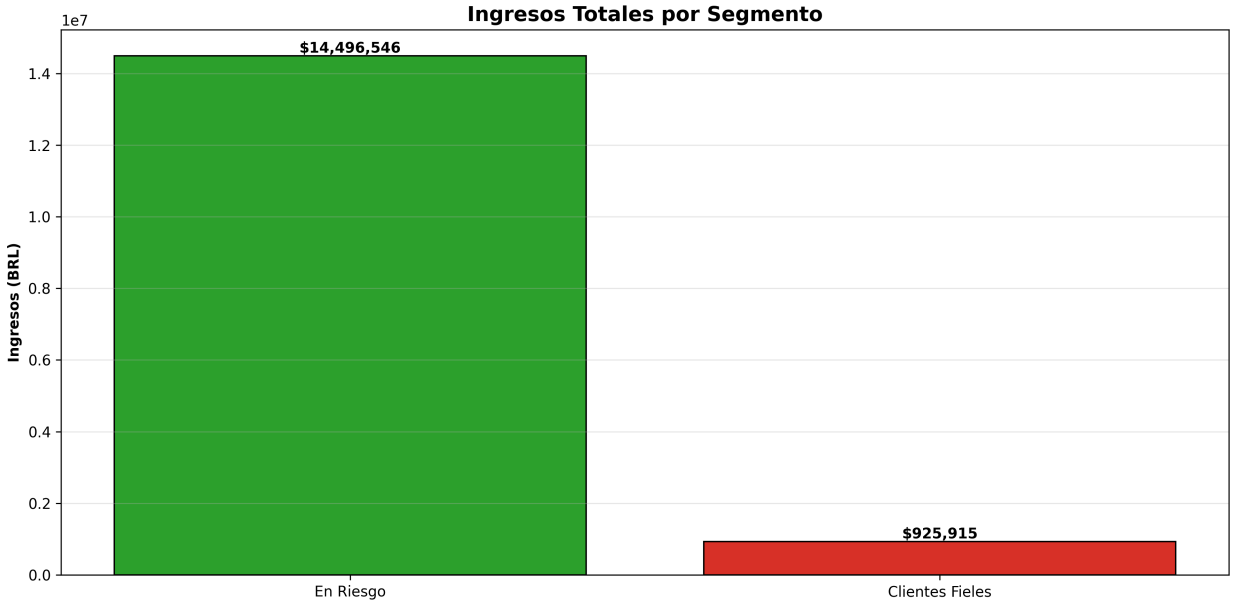

La visualización 3D permite observar la segmentación de una forma más intuitiva, viendo al mismo tiempo **recencia**, **frecuencia** y **gasto**.

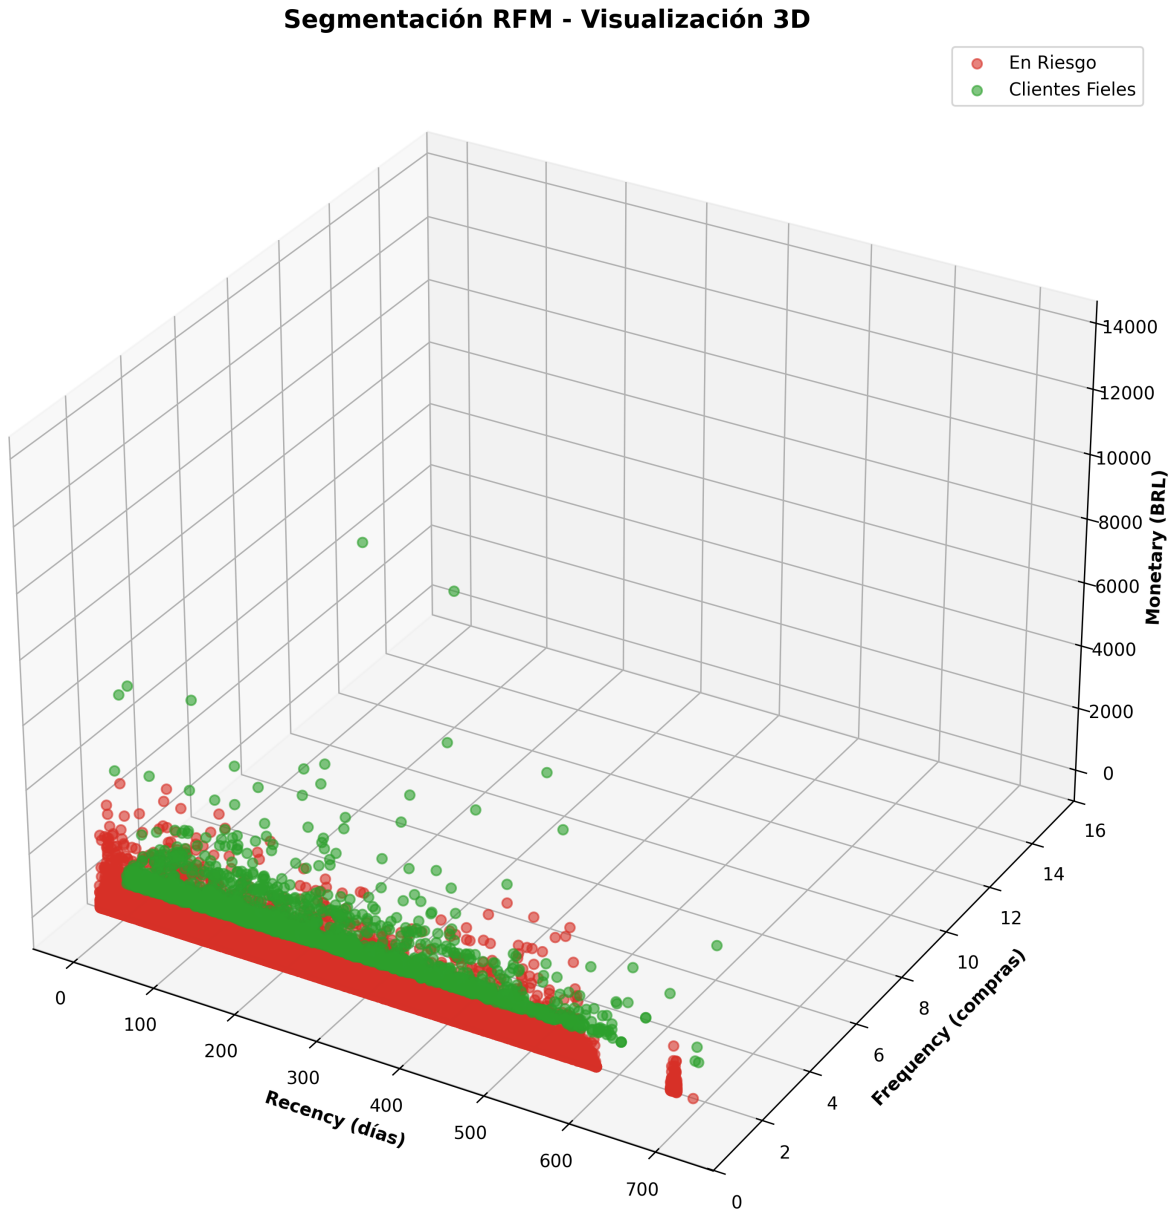

Arquitectura del modelo de recomendación en tiempo real

Se diseñó una arquitectura híbrida que combina señales de sesión activa del cliente con su historial de compras y perfil de segmento RFM. El sistema integra dos motores de recomendación complementarios con pesos dinámicos según el segmento.

Flujo de la arquitectura:

El siguiente diagrama resume visualmente el flujo completo, desde la captura de la sesión del cliente hasta la recomendación final que aparece en el portal web.

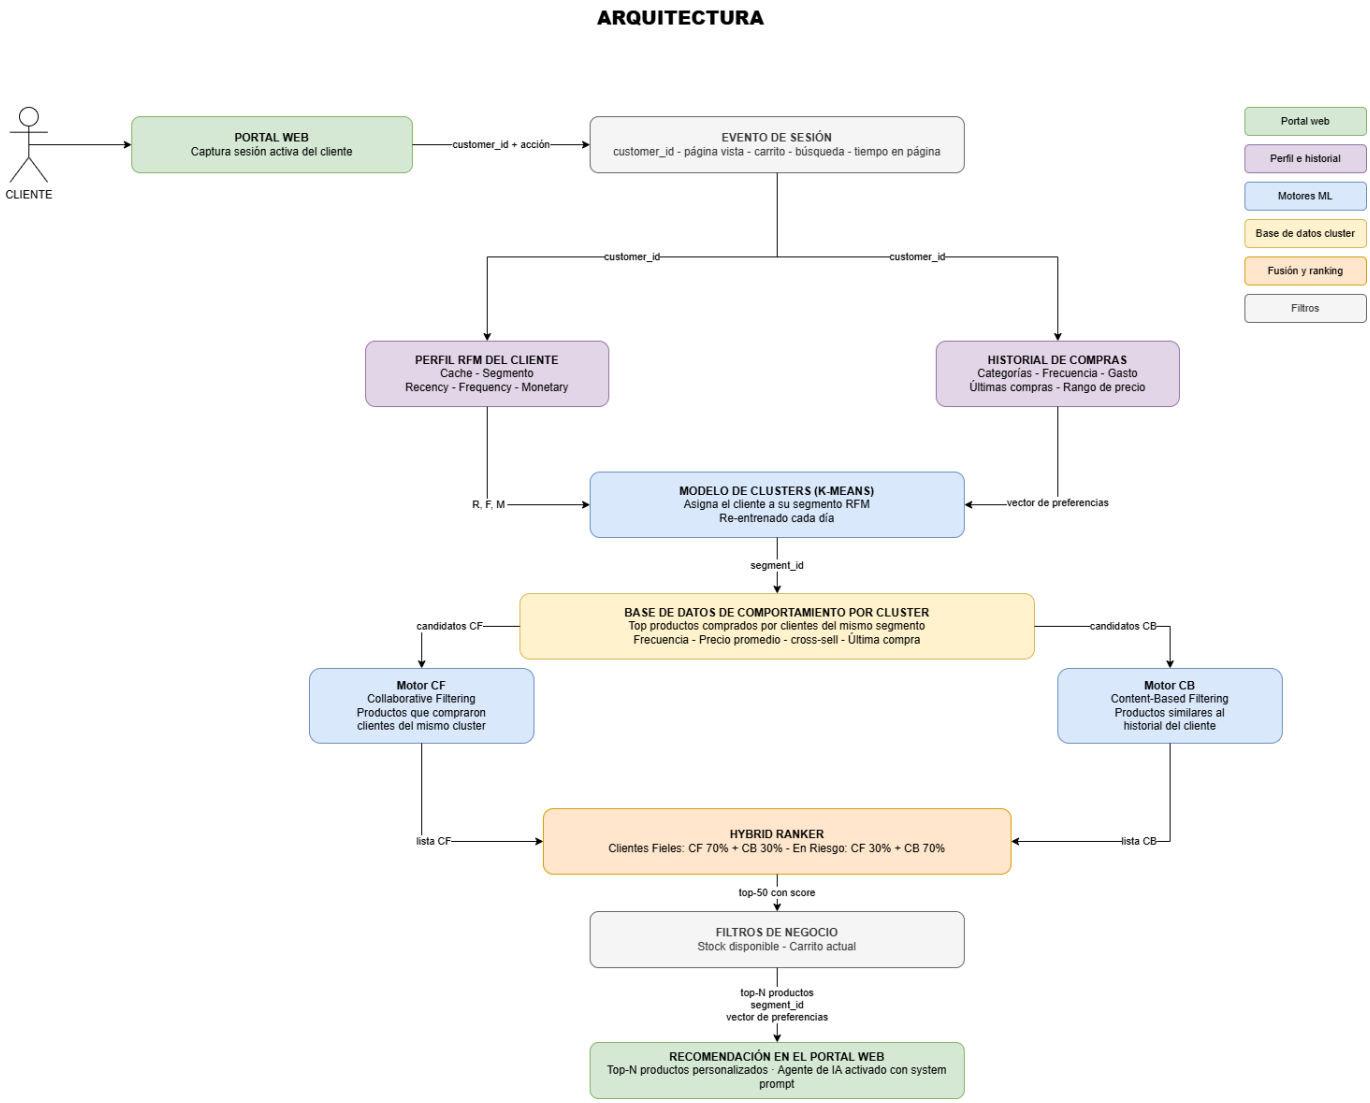

Pesos del Hybrid Ranker por segmento:

Segmento	CF	CB
Clientes Fieles	70%	30%
En Riesgo	30%	70%
Nuevos (cold start)	10%	90%

La diferencia fundamental entre CF y CB es la pregunta que responden: CF pregunta "¿qué compraron personas como tú?" mientras CB pregunta "¿qué productos se parecen a lo que ya compraste?". Combinarlos con pesos dinámicos por segmento reduce la rigidez de depender de un solo enfoque.

Implicaciones de negocio

- Integra intención actual y comportamiento histórico en una sola decisión.
- Permite recomendar distinto según el segmento del cliente sin reglas manuales.
- La capa de filtros de negocio evita recomendaciones técnicamente buenas pero comercialmente inviables.

Ubicación óptima del centro comercial insignia

Se analizaron las ventas por ciudad cruzando los datos de pedidos, pagos y geolocalización de clientes. Se calculó el ranking de ciudades por ingresos, la densidad de clientes únicos y las categorías con mejor desempeño por ciudad. La ubicación puntual dentro de la ciudad ganadora se determinó mediante un centroide ponderado por monto total gastado.

Ranking de ciudades:

Ciudad	Ingresos (BRL)	Clientes únicos
São Paulo (SP)	R$ 1,914,925	15,402
Rio de Janeiro (RJ)	R$ 992,539	6,834
Belo Horizonte (MG)	R$ 355,611	2,750
Brasilia (DF)	R$ 301,920	2,116
Curitiba (PR)	R$ 211,738	1,510

Categorías Top en São Paulo:

Categoría	Ingresos (BRL)
health_beauty	R$ 189,592
bed_bath_table	R$ 173,717
watches_gifts	R$ 166,536
sports_leisure	R$ 145,790
computers_accessories	R$ 145,527

São Paulo es la ubicación recomendada para el centro comercial insignia. Concentra la mayor cantidad de ingresos (R$ 1.9M), la mayor base de clientes (15,402) y la demanda más diversificada en categorías. Rio de Janeiro es el segundo mercado relevante pero representa menos de la mitad del volumen de São Paulo en todas las métricas y Belo Horizonte como una plaza interesante, pero de menor escala.

El mapa interactivo está disponible en results/answer_05/mapa_brasil_ingresos.html. Este refuerza la decisión al incorporar una marca de **ubicación óptima para tienda en São Paulo**.

El gráfico de ciudades por ingresos muestra el peso relativo de cada mercado y deja ver con claridad la distancia entre **São Paulo** y el resto de ciudades analizadas.

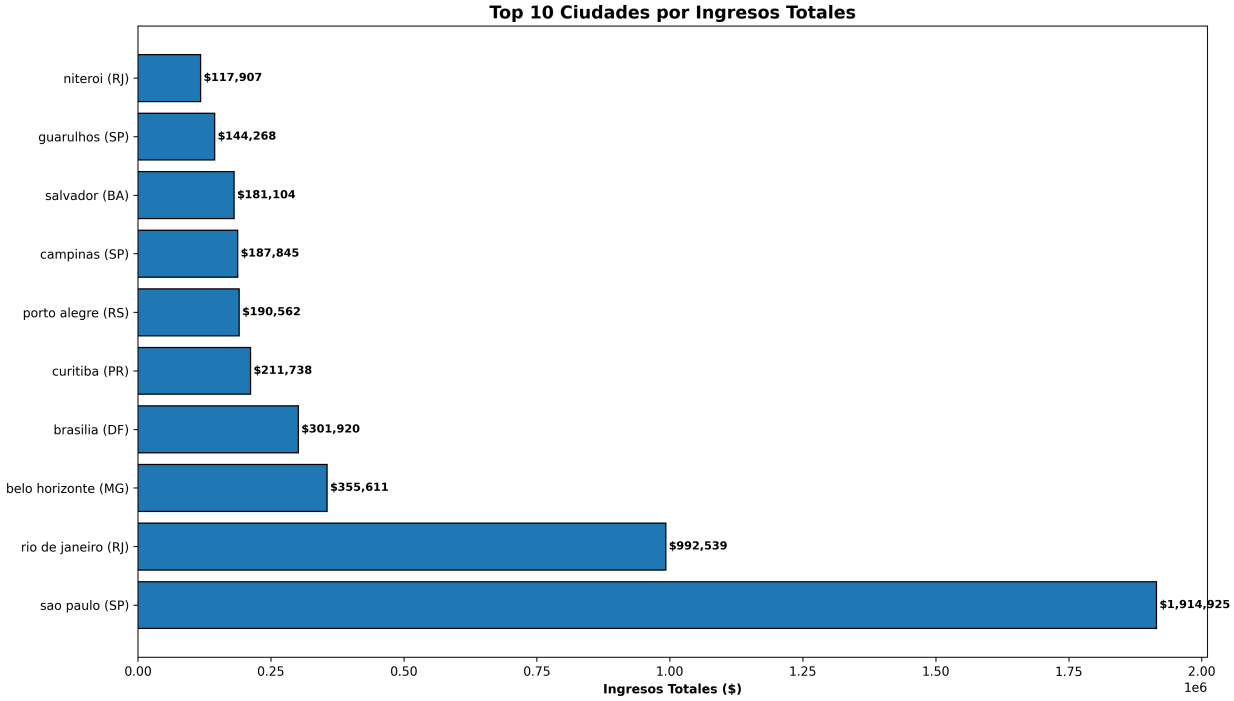

La matriz de clientes e ingresos ayuda a leer simultáneamente dos variables clave: **escala de base** y **capacidad de monetización**. Es útil para distinguir ciudades que no solo venden, sino que además concentran demanda suficiente para justificar una expansión.

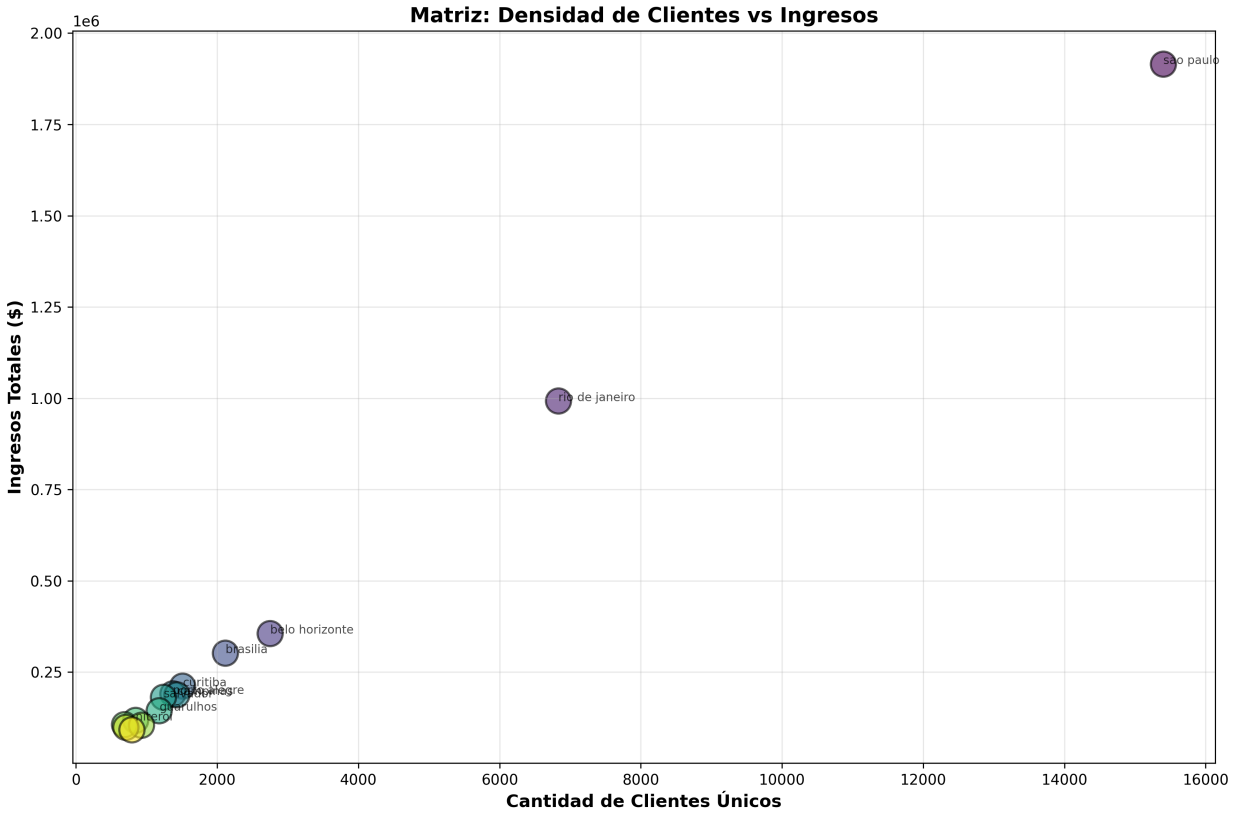

El gráfico de categorías por ciudad da contexto sobre qué tipos de producto sostienen el desempeño comercial en las plazas principales. Esto ayuda a entender si la oportunidad depende de una sola categoría o de una mezcla más robusta.

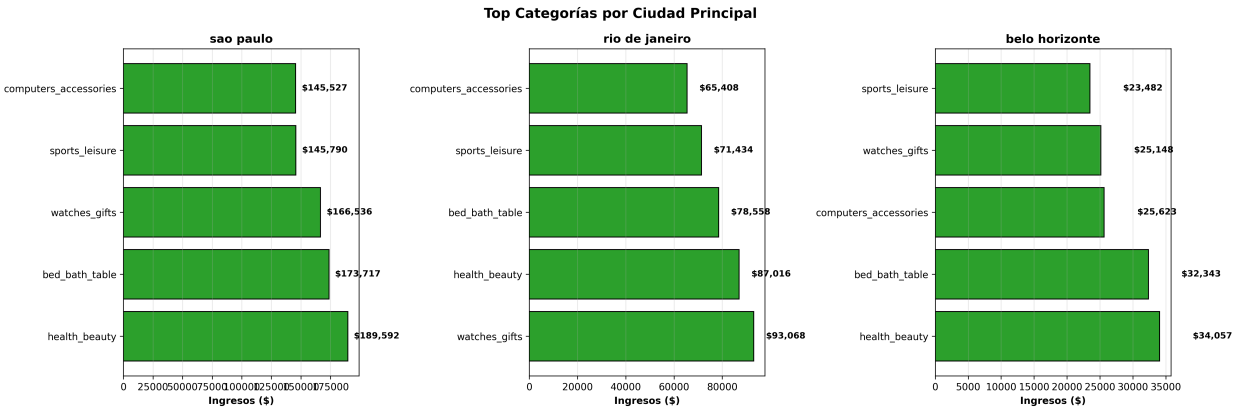

Base de conocimiento de productos

Se construyó una base de conocimientos en formato JSON con las 3 categorías top por volumen (identificadas en el Punto 1). Para cada categoría se extrajeron precios reales del dataset y se redactaron descripciones comerciales atractivas para uso del agente de IA. La base es reutilizable y se actualiza automáticamente al re-ejecutar el análisis.

Estructura de cada entrada:

- Precios reales: promedio, mediana, mínimo y máximo extraídos de `order_items`.
- Volumen vendido e ingresos totales.
- Descripción comercial atractiva redactada para el agente.
- Características clave del producto.

- Casos de uso recomendados.
- Oportunidades de cross-sell.
- Señales de estacionalidad.

Categorías incluidas:

Categoría	Precio promedio	Rango (BRL)	Unidades vendidas
Cama, Baño y Mesa	R$ 93.30	R$ 6.99 – R$ 1,999.98	11,115
Salud y Belleza	R$ 130.16	R$ 1.20 – R$ 3,124.00	9,670
Deportes y Ocio	R$ 114.34	R$ 4.50 – R$ 4,059.00	8,641

La inclusión de precios reales extraídos del dataset es especialmente valiosa porque permite que futuras recomendaciones se mantengan dentro de límites creíbles y el agente de IA haga referencias concretas y creíbles sin inventar rangos. Esto ayuda a evitar promesas poco realistas, mejora la consistencia comercial y conecta mejor el análisis con una posible experiencia conversacional o de recomendación.

Es importante tener en cuenta una limitación relevante en esta base de conocimiento, pues la información exportada cubre únicamente tres categorías, por lo que no representa la totalidad del catálogo.

La base de conocimiento está disponible en results/answer_06/knowledge_base.json.

Personalización del agente de IA

Se diseñaron 3 system prompts distintos para modular el tono y las recomendaciones del agente de IA según el perfil del cliente. Cada prompt ingiere 5 variables dinámicas en tiempo real y se conecta con la segmentación del Punto 3 y la base de conocimientos del Punto 6.

Variables dinámicas por prompt:

Variable	Fuente
`{EDAD}`	CRM del cliente
`{GENERO}`	CRM del cliente
`{PERFIL_CLIENTE}`	Segmento RFM — Punto 3
`{HISTORIAL_COMPRAS}`	Función `compute_purchase_history()` — dataset
`{BASE_CONOCIMIENTO}`	JSON exportado — Punto 6

Los 3 escenarios:

Escenario	Agente	Tono	Segmento objetivo
Joven digital frecuente	Nova	Fresco, directo, urgencia suave	Clientes Fieles

Escenario	Agente	Tono	Segmento objetivo
Mayor conservador con mala experiencia	Nova	Empático, claro, sin presión	En Riesgo
VIP corporativo	Luxa	Ejecutivo, consultivo, formal	Clientes Fieles

La diferencia de tono entre escenarios tiene impacto real en la experiencia, el agente empático de Nova para clientes con queja previa reconstruye confianza antes de hacer cualquier recomendación comercial, mientras Luxa para clientes VIP opera como asesor consultivo que anticipa necesidades en lugar de responder preguntas. Cada escenario cambia el tono, la prioridad de la conversación y la manera en que se presentan las recomendaciones. Esto permite que la experiencia no sea genérica, sino más adaptada a cada tipo de cliente.

Los resultados exportados incluyen tanto las **plantillas base** como **tres prompts renderizados**. En esos prompts finales se inyectan variables concretas como **edad**, **género**, **segmento CRM**, **historial de compras** y **base de conocimiento**.

Los tres escenarios generados fueron estos:

- Cliente de **27 años**, **masculino**, segmento **Clientes Fieles**, atendido por **Nova**.
- Cliente de **62 años**, **femenino**, segmento **En Riesgo**, atendido por **Nova**.
- Cliente de **45 años**, **masculino**, segmento **Clientes Fieles**, atendido por **Luxa**.

Los prompts renderizados están disponible en results/answer_07/prompts_renderizados.csv.

Conclusiones y próximos pasos

Conclusiones principales

- El 97% de la base de clientes está clasificada como "En Riesgo" con una frecuencia promedio de una compra, lo que convierte la reactivación y retención en las prioridades estratégicas más urgentes.
- São Paulo lidera en ingresos y clientes, siendo la única ciudad con escala suficiente para una tienda insignia.
- La combinación de segmentación RFM, recomendación híbrida (CF + CB) y agente de IA conversacional sienta una base sólida para adaptar la experiencia por tipo de cliente e integrar historial, sesión y perfil en cada interacción.

Próximos pasos recomendados

- **Corto plazo:** implementar campaña de reactivación para el segmento En Riesgo.
- **Mediano plazo:** desplegar el sistema de recomendación.
- **Largo plazo:** expandir la base de conocimientos a las top 20 categorías y conectar el agente de IA al canal de atención al cliente en producción.

El negocio tiene una base de ventas sólida pero debilidades claras en retención y experiencia. El mayor upside no está en adquirir más clientes, sino en extraer más valor de los existentes mediante personalización.